

Daftar isi

Kasus 1: Simulasi Estimasi Tarif Perjalanan Taksi di New York City2

Kasus 2: Simulasi Estimasi Biaya Premi Asuransi Kesehatan (Healthcare Insurance).....6

Kasus 3: Simulasi Valuasi Harga Properti dan Estimasi Nilai Jual Rumah (Ames Housing) 10

Kasus 4: Simulasi Estimasi Harga Berlian Berdasarkan Karakteristik Fisik (Diamond Pricing)..... 14

Kasus 5: Simulasi Estimasi Harga Jual Mobil Bekas (Used Car Valuation) 18

Panduan Penggunaan Data Sintetis dalam Tugas Kelompok22

Soal Tugas Kelompok: Pemodelan dan Simulasi

Materi 2: Model Regresi Cross-Sectional

Kasus 1: Simulasi Estimasi Tarif Perjalanan Taksi di New York City

1. Latar Belakang dan Tujuan

Efisiensi layanan transportasi publik di kota metropolis seperti New York sangat bergantung pada transparansi harga. Bagi perusahaan transportasi, mampu mengestimasi biaya perjalanan secara akurat berdasarkan variabel jarak dan waktu adalah kunci untuk menjaga kepuasan pelanggan dan efisiensi operasional. Masalah utama dalam pemodelan tarif taksi adalah sifat data yang dinamis, pengaruh jam sibuk (*rush hour*), serta keberadaan data pencilan (*outliers*) akibat kesalahan sensor GPS.

Simulasi ini bertujuan untuk membangun model regresi yang mampu memprediksi "**fare_amount**" (total tarif) berdasarkan posisi geografis dan waktu penjemputan. Mahasiswa ditantang untuk mengubah koordinat mentah (Latitude/Longitude) menjadi fitur jarak yang bermakna bagi mesin simulator.

Tujuan Tugas:

- 1. Mahasiswa mampu melakukan rekayasa fitur spasial (geografis) dan temporal (waktu) pada dataset skala besar.
- 2. Mahasiswa mampu membangun model regresi untuk mengestimasi nilai kuantitas kontinu secara akurat.
- 3. Mahasiswa mampu memberikan justifikasi ilmiah terhadap faktor-faktor yang paling memengaruhi tarif melalui teknik XAI dan simulasi intervensi.

2. Karakteristik Dataset

Dataset ini merupakan data kompetisi legendaris dari Google Cloud yang dipublikasikan di Kaggle.

- **Judul Dataset:** New York City Taxi Fare Prediction.
- **Tautan Sumber:** [Kaggle - NYC Taxi Fare](#).
- **Deskripsi:** Dataset ini sangat besar (lebih dari 50 juta baris pada versi lengkapnya). Mahasiswa disarankan melakukan *random sampling* (misal: 100.000 - 500.000 baris) agar dapat diolah di Google Colab.

Atribut Data:

Nama Atribut	Deskripsi	Tipe Data
<code>pickup_datetime</code>	Waktu dan tanggal saat penumpang naik taksi.	Datetime/String
<code>pickup_longitude</code>	Koordinat bujur lokasi penjemputan.	Float
<code>pickup_latitude</code>	Koordinat lintang lokasi penjemputan.	Float
<code>dropoff_longitude</code>	Koordinat bujur lokasi tujuan.	Float
<code>dropoff_latitude</code>	Koordinat lintang lokasi tujuan.	Float
<code>passenger_count</code>	Jumlah penumpang dalam satu perjalanan.	Integer
<code>fare_amount</code>	Label Target: Total tarif perjalanan (\$).	Float

3. Pembagian Tugas dan Peran (Individual Job Desc)

Tugas dikerjakan oleh **2 mahasiswa per kelompok**. Laporan dan presentasi dilakukan secara mandiri oleh tiap anggota sesuai peran berikut:

Mahasiswa ke-1: Data Architect & Engineer

Fokus: Validasi geospasial, rekayasa fitur waktu, dan pembersihan data Big Data.

- 1. **Data Ingestion & Sampling:** Melakukan akuisisi data dan sampling representatif dari file mentah yang besar.
- 2. **Spatial Cleaning:** Menghapus data koordinat yang tidak logis (misal: koordinat di luar wilayah NYC atau di tengah laut).
- 3. **Feature Engineering (Distance):** Menghitung jarak perjalanan (seperti rumus *Haversine* atau *Euclidean*) dari koordinat pickup ke dropoff.
- 4. **Temporal Extraction:** Menguraikan `pickup_datetime` menjadi fitur baru: Jam (Hour), Hari (Day of Week), dan Bulan untuk menangkap pola jam sibuk.

5. **Preprocessing Pipeline:** Melakukan standarisasi fitur numerik menggunakan `StandardScaler`.

Mahasiswa ke-2: Model Analyst & Strategist

Fokus: Arsitektur regresi, evaluasi galat, transparansi fitur, dan simulasi biaya.

- Regression Modeling:** Eksperimentasi algoritma regresi (Linear, SGD, atau algoritma non-linear lainnya) untuk meminimalkan galat prediksi.
- Model Assessment:** Evaluasi kualitas peramalan menggunakan metrik MAE (Mean Absolute Error), RMSE (Root Mean Squared Error), dan R-Squared (R^2).
- Explainable AI (XAI):** Menggunakan SHAP untuk menganalisis kontribusi fitur (misal: apakah jarak lebih berpengaruh daripada jam penjemputan?).
- Policy Simulation:** Melakukan uji coba skenario "What-If" menggunakan **Data Sintetis**: "Bagaimana jika jarak tetap namun perjalanan dilakukan pada jam sibuk (Pukul 17:00)? Berapa kenaikan tarif yang diprediksi simulator?"

4. Landasan Ilmiah (Tabel Sintesis Jurnal)

Mahasiswa wajib menyertakan tabel sintesis dari minimal **6 artikel jurnal ilmiah** (maksimal 5 tahun terakhir).

- Jurnal Nasional:** Terakreditasi SINTA 1, 2, 3, atau 4.
- Jurnal Internasional:** Scopus, WoS, DOAJ, PubMed, atau IEEE Xplore.

Contoh Tabel Sintesis yang Baik:

No	Info Artikel (Penulis, Judul, Jurnal, Vol, No, Tahun, Tautan)	Metode	Temuan Utama	Relevansi
1	Wijaya, B., "Estimasi Tarif Transportasi Online," <i>Jurnal Informatika</i> , 8(1), 2023, [https://doi.org/xxx]	Regresi Linear	Fitur waktu (jam) memberikan pengaruh 15% pada akurasi tarif.	Dasar ekstraksi fitur temporal.
2	Smith, K., "Geospatial ML for NYC," <i>Scientific Reports</i> , 12(3), 2024, [https://doi.org/yyy]	Haversine + SGD	Rumus Haversine lebih akurat 20% dibanding Euclidean untuk NYC.	Rujukan perhitungan jarak.

Kesimpulan Sintesis: Mahasiswa wajib memberikan narasi kesimpulan mengenai metode pembersihan data dan pemilihan algoritma yang paling efektif berdasarkan 6 literatur tersebut.

5. Alur Kerja (ML Pipeline)

Penyelesaian harus selaras dengan buku **PEMODELAN DAN SIMULASI BERBASIS MACHINE LEARNING**:

- Data Acquisition:** Memuat dataset Kaggle (gunakan teknik sampling untuk efisiensi).
- Data Cleaning:** Penanganan outlier koordinat (NYC range: Lat 40-42, Long -73 s.d -75).
- Feature Engineering:** Pembuatan kolom Jarak dan ekstraksi Waktu.
- Modeling Phase:** Implementasi algoritma regresi pilihan kelompok.
- Model Assessment:** Evaluasi metrik R^2 , MAE, dan RMSE.
- Explainability (XAI):** Visualisasi kontribusi fitur menggunakan SHAP.
- Simulation & What-If:** Menguji skenario tarif menggunakan data input buatan (sintetis).

6. Deskripsi Program Aplikasi

Aplikasi harus memiliki modul simulator yang mampu menerima input: **Lokasi Jemput (Lat/Long)**, **Lokasi Tujuan (Lat/Long)**, dan **Jam Penjemputan**. Output yang dihasilkan adalah: **"ESTIMASI TARIF PERJALANAN (USD)"**.

Cara Menguji Program:

Mahasiswa wajib menguji minimal **10 sampel data acak** (mencakup jarak dekat dan jarak jauh).

- Hubungan dengan Model Assessment:** Jika model memiliki R^2 yang rendah, maka hasil prediksi manual pada 10 sampel ini akan sering meleset jauh dari tarif yang wajar (seperti tarif negatif atau tarif yang terlalu mahal).

7. Hasil dan Pembahasan

Bagian ini wajib menyajikan:

- Analisis Geospasial:** Visualisasi sebaran lokasi penjemputan (Scatter plot koordinat).
- Perbandingan Metrik:** Tabel performa model pada data training vs data testing.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

- **Visualisasi SHAP:** Analisis fitur mana yang paling dominan menentukan mahal nya tarif (Jarak vs Waktu).
- **Hasil What-If (Data Sintetis):** Tabel perbandingan tarif pada rute yang sama namun jam yang berbeda (Pagi vs Sore).

8. Sistematika Laporan & Presentasi

Semua berkas diawali dengan **Cover** (Identitas Mahasiswa & Judul Kasus).

Mahasiswa ke-1 (Data Engineer)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Preprocessing, Kesimpulan Sintesis).
- **Bab II: Metodologi Rekayasa Data** (Pipeline Preprocessing, Logika Perhitungan Jarak, Teknik Ekstraksi Waktu).
- **Bab III: Hasil & Pembahasan** (Analisis Statistik Fitur Baru, Visualisasi Koordinat, Efektivitas Pembersihan Data).
- **Lampiran:** Script Program (Bagian Data Engineering).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Rekayasa Data Spasial.
- 3: Alur Transformasi Koordinat ke Jarak.
- 4: Analisis Data Sebelum dan Sesudah Pembersihan.

Mahasiswa ke-2 (Model Strategist)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Regresi/XAI, Kesimpulan Sintesis).
- **Bab II: Metodologi Pemodelan & Simulasi** (Pemilihan Algoritma Regresi, Optimasi Parameter, Metode Evaluasi).
- **Bab III: Hasil & Pembahasan** (Analisis Galat MAE/RMSE, Interpretasi SHAP, Simulasi Tarif dengan Data Sintetis).
- **Lampiran:** Script Program (Bagian Modeling & Simulation).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Algoritma Regresi.
- 3: Arsitektur Model & Hasil Evaluasi Metrik.
- 4: Penjelasan Logika Tarif (SHAP).
- 5: Simulasi Skenario Biaya (What-If Analysis).

9. Ketentuan Pengumpulan dan File

PERINGATAN: Algoritma antar kelompok **TIDAK BOLEH SAMA**. Segera klaim algoritma Anda melalui Google Form "**Klaim Metode Materi 2**".

- **Batas Waktu:** Cek file "Ringkasan Penugasan Pemodelan dan Simulasi 2026".
- **Link Pengumpulan:** Form "UNGGAH FILE JAWABAN" di deskripsi WAG.
- **Informasi Penting Pengumpulan:**
 - **Nama file bebas.**
 - **Format file harus sesuai** (PDF untuk dokumen/presentasi, MP4 untuk video).
 - **Kode soal harus sesuai** (P21 / P22 / R2).
 - **Jenis harus sesuai** (LAPORAN / PRESENTASI).
- **File yang dikumpulkan (Masing-masing Anggota):**
 - **PDF Laporan;** kode soal: **P21**; jenis: **LAPORAN**; format: **PDF**
 - **PDF Presentasi;** kode soal: **P22**; jenis: **LAPORAN**; format: **PDF**
 - **Video Presentasi;** kode soal: **R2**; jenis: **PRESENTASI**; format: **MP4** (720p, Wajib Video Overlay wajah presenter).

10. Penyesuaian untuk Kelompok Tunggal (1 Anggota)

Penyesuaian Beban Kerja

Mahasiswa mengerjakan seluruh alur (Data Engineer + Model Strategist) dengan kompensasi:

- Jumlah jurnal pada tabel sintesis minimal **3 jurnal**.
- Sampel uji simulator minimal **5 sampel**.

Sistematika Laporan (Kelompok Tunggal)

- **Bab I:** Pendahuluan & Sintesis Jurnal.
- **Bab II:** Metodologi (Data Engineering hingga Modeling).
- **Bab III:** Hasil & Pembahasan (Integrasi Performa & XAI).

Konten Presentasi (Kelompok Tunggal)

Mencakup ringkasan eksekutif dari pengolahan data hingga hasil simulasi kebijakan dalam satu file presentasi (P22) dan video (R2).

Soal Tugas Kelompok: Pemodelan dan Simulasi

Materi 2: Model Regresi Cross-Sectional

Kasus 2: Simulasi Estimasi Biaya Premi Asuransi Kesehatan (Healthcare Insurance)

1. Latar Belakang dan Tujuan

Industri asuransi kesehatan mengandalkan estimasi biaya klaim yang akurat untuk menentukan besaran premi bagi nasabah. Penetapan harga yang salah dapat menyebabkan kerugian besar bagi perusahaan atau ketidakadilan bagi nasabah. Biaya kesehatan dipengaruhi oleh kombinasi kompleks antara faktor demografi (usia, wilayah) dan gaya hidup (Indeks Massa Tubuh/BMI, kebiasaan merokok). Masalah utama dalam pemodelan ini adalah adanya interaksi non-linear antara variabel, seperti pengaruh kebiasaan merokok yang meningkat secara eksponensial seiring bertambahnya usia. Simulasi ini bertujuan untuk membangun model regresi yang mampu memprediksi "**charges**" (biaya premi/klaim) nasabah secara presisi, sehingga institusi kesehatan dapat melakukan simulasi finansial yang lebih terukur.

Tujuan Tugas:

- 1. Mahasiswa mampu mengolah data demografi dan gaya hidup (kategorikal & numerik) menjadi fitur prediktor yang valid.
- 2. Mahasiswa mampu membangun model regresi untuk mengestimasi nilai biaya kesehatan kontinu.
- 3. Mahasiswa mampu membuktikan secara ilmiah faktor risiko utama (Risk Factors) melalui teknik XAI dan simulasi "What-If" pada profil nasabah.

2. Karakteristik Dataset

Dataset ini berisi informasi biaya medis personal yang sering digunakan dalam studi aktuaria asuransi.

- **Judul Dataset:** Medical Cost Personal Datasets.
- **Tautan Sumber:** [Kaggle - Healthcare Insurance Dataset](#).
- **Deskripsi:** Terdiri dari 1.338 baris data nasabah asuransi dengan fitur yang mencakup karakteristik fisik dan perilaku.

Atribut Data:

Nama Atribut	Deskripsi	Tipe Data
age	Usia nasabah utama.	Integer
sex	Jenis kelamin nasabah (female, male).	Kategorikal
bmi	Indeks Massa Tubuh (Body Mass Index) (kg/m^2).	Float
children	Jumlah anak/tanggungan yang dicover asuransi.	Integer
smoker	Apakah nasabah merokok (yes, no).	Kategorikal
region	Wilayah tempat tinggal nasabah di AS.	Kategorikal
charges	Label Target: Biaya medis individu yang ditagih oleh asuransi.	Float

3. Pembagian Tugas dan Peran (Individual Job Desc)

Tugas dikerjakan oleh **2 mahasiswa per kelompok**. Laporan dan presentasi dilakukan secara mandiri oleh tiap anggota sesuai peran berikut:

Mahasiswa ke-1: Data Architect & Engineer

Fokus: Encoding variabel kategori, penanganan outlier, dan distribusi fitur.

- 1. **Data Ingestion:** Akuisisi dataset dan audit kualitas data awal.
- 2. **Feature Encoding:** Menerapkan strategi *One-Hot Encoding* atau *Label Encoding* pada variabel `smoker`, `sex`, dan `region`.
- 3. **Outlier Management:** Identifikasi dan penanganan nilai ekstrim pada variabel `charges` dan `bmi` yang dapat mengganggu garis regresi.
- 4. **Correlation Analysis:** Visualisasi hubungan antara gaya hidup (merokok/BMI) terhadap biaya kesehatan.
- 5. **Data Transformation:** Melakukan standarisasi atau normalisasi fitur numerik agar model konvergen lebih cepat.

Mahasiswa ke-2: Model Analyst & Strategist

Fokus: Arsitektur regresi, evaluasi presisi, dan simulasi biaya risiko.

- 1. **Model Implementation:** Eksperimentasi algoritma regresi (Linear, Polinomial, atau regresi cerdas lainnya) yang mampu menangani data asuransi.
- 2. **Model Assessment:** Evaluasi galat menggunakan metrik MAE, RMSE, dan R^2 (Koefisien Determinasi).
- 3. **Explainable AI (XAI):** Menggunakan SHAP untuk membuktikan seberapa besar kenaikan biaya jika seorang nasabah adalah perokok berat dibandingkan nasabah sehat.
- 4. **Policy Simulation:** Melakukan uji coba skenario "What-If" menggunakan **Data Sintetis**: "Jika seorang nasabah dengan BMI tinggi memutuskan berhenti merokok, berapa estimasi penurunan premi yang bisa diberikan oleh simulator?"

4. Landasan Ilmiah (Tabel Sintesis Jurnal)

Mahasiswa wajib menyertakan tabel sintesis dari minimal **6 artikel jurnal ilmiah** (maksimal 5 tahun terakhir).

- **Jurnal Nasional:** Terakreditasi SINTA 1-4.
- **Jurnal Internasional:** Scopus, WoS, DOAJ, PubMed, atau IEEE Xplore.

Contoh Tabel Sintesis yang Baik:

No	Info Artikel (Penulis, Judul, Jurnal, Vol, No, Tahun, Tautan)	Metode	Temuan Utama	Relevansi
1	Ramadhan, F., "Prediksi Klaim Asuransi," <i>Jurnal Aktuaria</i> , 5(2), 2023, [URL]	Regresi Polinomial	Usia memiliki hubungan kuadratik terhadap biaya kesehatan.	Dasar penentuan derajat polinomial.
2	Gupta, S., "Insurance Pricing with XAI," <i>Health Tech Journal</i> , 9(1), 2024, [URL]	Random Forest + SHAP	Status merokok menyumbang 60% dari variansi total biaya.	Rujukan analisis kontribusi fitur.

Kesimpulan Sintesis: Mahasiswa wajib merangkum tren metode dan variabel yang dianggap paling berpengaruh secara ilmiah berdasarkan 6 literatur tersebut.

5. Alur Kerja (ML Pipeline)

Penyelesaian harus selaras dengan buku **PEMODELAN DAN SIMULASI BERBASIS MACHINE LEARNING**:

- 1. **Data Acquisition:** Memuat dataset asuransi dari Kaggle secara terprogram.
- 2. **EDA & Visualisasi:** Memahami sebaran biaya berdasarkan kategori perokok dan BMI.
- 3. **Preprocessing:** Encoding fitur teks ke numerik dan penskalaan.
- 4. **Modeling Phase:** Implementasi algoritma regresi pilihan kelompok.
- 5. **Model Assessment:** Evaluasi performa pada data uji (Test Set).
- 6. **Explainability (XAI):** Analisis faktor pendorong premi menggunakan SHAP.
- 7. **Simulation & What-If:** Pengujian kebijakan diskon premi berbasis gaya hidup sehat menggunakan data input buatan (sintetis).

6. Deskripsi Program Aplikasi

Aplikasi harus memiliki modul simulator yang mampu menerima input: **Usia, BMI, Status Merokok**, dan **Wilayah**. Output yang dihasilkan adalah: **"ESTIMASI BIAYA PREMI TAHUNAN (USD)"**.

Cara Menguji Program:

Mahasiswa wajib menguji minimal **10 sampel data acak** (mencakup kategori perokok dan non-perokok).

- **Hubungan dengan Model Assessment:** Jika model memiliki R^2 yang rendah, maka simulator mungkin gagal membedakan perbedaan biaya yang signifikan antara perokok dan non-perokok pada pengujian manual ini.

7. Hasil dan Pembahasan

Bagian ini wajib menyajikan:

- **Analisis Gaya Hidup:** Visualisasi biaya kesehatan berdasarkan status merokok (Boxplot/Violin Plot).
- **Analisis Error:** Grafik *Residual Plot* untuk melihat apakah galat terdistribusi secara acak.
- **Analisis Kontribusi (SHAP):** Penjelasan mengapa nasabah tertentu dikenakan premi sangat tinggi.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

- **Hasil What-If (Data Sintetis):** Tabel simulasi perubahan biaya ketika variabel BMI atau Status Merokok dimanipulasi secara virtual.

8. Sistematika Laporan & Presentasi

Semua berkas diawali dengan **Cover** (Identitas Mahasiswa & Judul Kasus).

Mahasiswa ke-1 (Data Engineer)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Preprocessing, Kesimpulan Sintesis).
- **Bab II: Metodologi Rekayasa Data** (Pipeline Encoding, Logika Penanganan Outlier, Teknik Transformasi Skala).
- **Bab III: Hasil & Pembahasan** (Analisis Statistik, Visualisasi Hubungan Antar Fitur, Efektivitas Preprocessing).
- **Lampiran:** Script Program (Bagian Data Engineering).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Rekayasa Data Medis.
- 3: Alur Transformasi Fitur Kategorikal.
- 4: Analisis Outlier dan Sebaran Data Biaya.

Mahasiswa ke-2 (Model Strategist)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Regresi/XAI, Kesimpulan Sintesis).
- **Bab II: Metodologi Pemodelan & Simulasi** (Pemilihan Algoritma, Strategi Optimasi Parameter, Metode Evaluasi).
- **Bab III: Hasil & Pembahasan** (Analisis Presisi MAE/RMSE, Interpretasi SHAP, Simulasi Kebijakan Premi dengan Data Sintetis).
- **Lampiran:** Script Program (Bagian Modeling & Simulation).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Algoritma Regresi Medis.
- 3: Arsitektur Model & Metrik Evaluasi Akhir.
- 4: Penjelasan Logika Biaya (SHAP).
- 5: Simulasi Skenario Perubahan Gaya Hidup (What-If).

9. Ketentuan Pengumpulan dan File

PERINGATAN: Algoritma antar kelompok **TIDAK BOLEH SAMA**. Segera klaim algoritma Anda melalui Google Form "**Klaim Metode Materi 2**".

- **Batas Waktu:** Cek file "Ringkasan Penugasan Pemodelan dan Simulasi 2026".
- **Link Pengumpulan:** Form "UNGGAH FILE JAWABAN" di deskripsi WAG.
- **Informasi Penting Pengumpulan:**
 - Nama file bebas.
 - Format file harus sesuai (PDF untuk dokumen/presentasi, MP4 untuk video).
 - Kode soal harus sesuai (P21 / P22 / R2).
 - Jenis harus sesuai (LAPORAN / PRESENTASI).
- **File yang dikumpulkan (Masing-masing Anggota):**
 - **PDF Laporan;** kode soal: **P21**; jenis: **LAPORAN**; format: **PDF**
 - **PDF Presentasi;** kode soal: **P22**; jenis: **LAPORAN**; format: **PDF**
 - **Video Presentasi;** kode soal: **R2**; jenis: **PRESENTASI**; format: **MP4** (720p, Wajib Video Overlay wajah presenter).

10. Penyesuaian untuk Kelompok Tunggal (1 Anggota)

Penyesuaian Beban Kerja

Mahasiswa mengerjakan seluruh alur dengan kompensasi:

- Jumlah jurnal pada tabel sintesis minimal **3 jurnal**.
- Sampel uji simulator minimal **5 sampel**.

Sistematika Laporan (Kelompok Tunggal)

- **Bab I:** Pendahuluan & Sintesis Jurnal.
- **Bab II:** Metodologi (Data Engineering hingga Modeling).
- **Bab III:** Hasil & Pembahasan (Integrasi Performa & XAI).

Konten Presentasi (Kelompok Tunggal)

Mencakup ringkasan eksekutif dari pengolahan data hingga hasil simulasi kebijakan dalam satu file presentasi (P22) dan video (R2).

Soal Tugas Kelompok: Pemodelan dan Simulasi

Materi 2: Model Regresi Cross-Sectional

Kasus 3: Simulasi Valuasi Harga Properti dan Estimasi Nilai Jual Rumah (Ames Housing)

1. Latar Belakang dan Tujuan

Penentuan nilai pasar sebuah properti merupakan tantangan kompleks yang melibatkan berbagai variabel, mulai dari luas bangunan, kualitas material, hingga faktor lokasi dan fasilitas pendukung. Bagi perusahaan properti dan penilai pajak, memiliki sistem estimasi otomatis yang akurat sangat krusial untuk menjaga transparansi harga dan efisiensi transaksi.

Masalah utama dalam kasus ini adalah **High Dimensionality**, di mana terdapat 79 variabel yang mendeskripsikan hampir setiap aspek dari sebuah rumah tinggal. Simulasi ini bertujuan untuk membangun model regresi yang mampu memprediksi **"SalePrice"** (harga jual) secara presisi. Mahasiswa ditantang untuk melakukan seleksi fitur yang cerdas agar model tetap efisien tanpa kehilangan informasi krusial.

Tujuan Tugas:

- 1. Mahasiswa mampu melakukan rekayasa fitur pada data dengan jumlah atribut yang sangat banyak.
- 2. Mahasiswa mampu membangun model regresi cerdas untuk mengestimasi nilai aset properti.
- 3. Mahasiswa mampu melakukan audit fungsional dan analisis sensitivitas (What-If) untuk memahami variabel mana yang paling meningkatkan nilai jual sebuah rumah.

2. Karakteristik Dataset

Dataset yang digunakan adalah *Ames Housing Dataset*, yang sering disebut sebagai versi modern dan lebih kompleks dari dataset perumahan Boston.

- **Judul Dataset:** Ames Housing Dataset for Data Science Itineraries.
- **Tautan Sumber:** [Kaggle - Ames Housing](#).
- **Deskripsi:** Berisi deskripsi properti rumah tinggal di Ames, Iowa. Terdiri dari 1.460 baris data observasi.

Atribut Data (Beberapa Contoh Krusial):

Nama Atribut	Deskripsi	Tipe Data
OverallQual	Kualitas material dan penyelesaian rumah (1-10).	Ordinal/Integer
GrLivArea	Luas area ruang tamu di atas permukaan tanah (kaki persegi).	Float/Integer
TotalBsmntSF	Luas area total basement (kaki persegi).	Float/Integer
YearBuilt	Tahun asli konstruksi dibangun.	Integer
Neighborhood	Lokasi fisik di dalam batas kota Ames.	Kategorikal
SalePrice	Label Target: Harga jual properti dalam dollar (\$).	Float

3. Pembagian Tugas dan Peran (Individual Job Desc)

Tugas dikerjakan oleh **2 mahasiswa per kelompok**. Laporan dan presentasi dilakukan secara mandiri oleh tiap anggota sesuai peran berikut:

Mahasiswa ke-1: Data Architect & Engineer

Fokus: Strategi penanganan missing values, encoding ordinal, dan seleksi fitur.

- 1. **Data Cleaning:** Menangani *missing values* yang tersebar di banyak kolom (seperti `PoolQC`, `MiscFeature`, `Alley`).
- 2. **Feature Encoding:** Menerapkan strategi yang tepat untuk data ordinal (seperti `OverallQual`) dan nominal (seperti `Neighborhood`).
- 3. **Correlation Analysis:** Melakukan analisis korelasi untuk mereduksi fitur yang redundan atau tidak memiliki pengaruh signifikan terhadap harga.
- 4. **Outlier Detection:** Mengidentifikasi dan menangani data rumah yang tidak lazim (misal: luas sangat besar tapi harga sangat murah).
- 5. **Preprocessing Pipeline:** Melakukan normalisasi atau transformasi logaritma pada target `SalePrice` jika distribusi data menunjukkan kecondongan (*skewness*).

Mahasiswa ke-2: Model Analyst & Strategist

Fokus: Eksperimentasi model regresi, evaluasi presisi, dan interpretasi nilai aset.

- 1. **Regression Modeling:** Eksperimentasi algoritma regresi (Linear, Lasso, Ridge, atau model cerdas lainnya) untuk menangani fitur berdimensi tinggi.
- 2. **Model Assessment:** Evaluasi kualitas peramalan menggunakan metrik MAE, RMSE, dan R^2 .
- 3. **Explainable AI (XAI):** Menggunakan SHAP untuk membongkar variabel fisik mana yang paling "mahal" bagi sebuah rumah.
- 4. **Valuation Simulation:** Melakukan uji coba skenario "What-If" menggunakan **Data Sintetis**: "Jika sebuah rumah dengan kualitas rendah dilakukan renovasi (meningkatkan OverallQual), berapa estimasi kenaikan harga jual yang diprediksi oleh simulator?"

4. Landasan Ilmiah (Tabel Sintesis Jurnal)

Mahasiswa wajib menyertakan tabel sintesis dari minimal **6 artikel jurnal ilmiah** (maksimal 5 tahun terakhir).

- **Jurnal Nasional:** Terakreditasi SINTA 1, 2, 3, atau 4.
- **Jurnal Internasional:** Scopus, WoS, DOAJ, PubMed, atau IEEE Xplore.

Contoh Tabel Sintesis yang Baik:

No	Info Artikel (Penulis, Judul, Jurnal, Vol, No, Tahun, Tautan)	Metode	Temuan Utama	Relevansi
1	Saputra, H., "Estimasi Harga Properti," <i>Jurnal Sistem Cerdas</i> , 10(1), 2023, [URL]	Lasso Regression	Fitur luas tanah menyumbang 45% akurasi harga properti.	Dasar seleksi fitur properti.
2	White, L., "Explainable Valuation," <i>Property Tech Journal</i> , 5(2), 2024, [URL]	JST + SHAP	Kualitas material adalah prediktor paling dominan dibanding lokasi.	Rujukan interpretasi model (XAI).

Kesimpulan Sintesis: Mahasiswa wajib memberikan narasi kesimpulan mengenai tren teknik pemrosesan data dan algoritma yang paling sukses untuk valuasi properti berdasarkan 6 literatur tersebut.

5. Alur Kerja (ML Pipeline)

Penyelesaian harus selaras dengan buku **PEMODELAN DAN SIMULASI BERBASIS MACHINE LEARNING**:

- 1. **Data Acquisition:** Memuat dataset Ames Housing dari Kaggle secara terprogram.
- 2. **EDA & Visualisasi:** Memahami distribusi harga jual dan korelasi antar fitur.
- 3. **Handling Missing Values:** Implementasi pengisian data kosong secara sistematis.
- 4. **Encoding & Scaling:** Transformasi fitur heterogen ke format numerik standar.
- 5. **Modeling:** Implementasi algoritma regresi pilihan kelompok.
- 6. **Model Assessment:** Evaluasi galat pada data uji.
- 7. **Explainability (XAI):** Analisis faktor pendorong nilai jual menggunakan SHAP.
- 8. **Simulasi Intervensi:** Pengujian skenario "What-If" (Renovasi Properti) menggunakan data sintetis.

6. Deskripsi Program Aplikasi

Aplikasi harus memiliki modul simulator yang mampu menerima input spesifikasi rumah (misal: luas, kualitas, tahun bangun) dan mengeluarkan output: **"ESTIMASI HARGA PASAR (USD)"**.

Cara Menguji Program:

Mahasiswa wajib menguji minimal **10 sampel data acak** dari data uji.

- **Hubungan dengan Model Assessment:** Kesuksesan pada 10 sampel ini harus merefleksikan nilai R^2 . Jika model memiliki bias, maka pada sampel rumah mewah model mungkin akan memberikan estimasi yang terlalu rendah (*underestimation*).

7. Hasil dan Pembahasan

Bagian ini wajib menyajikan:

- **Analisis Preprocessing:** Perbandingan jumlah fitur sebelum dan sesudah seleksi fitur/pembersihan.
- **Analisis Error:** Visualisasi grafik *Actual vs Predicted* untuk melihat persebaran galat.
- **Visualisasi SHAP:** Penjelasan fitur fisik mana yang paling krusial menentukan kenaikan harga jual.
- **Hasil What-If (Data Sintetis):** Tabel perbandingan harga rumah asli vs harga rumah setelah disimulasikan melalui skenario renovasi (perubahan kualitas).

8. Sistematika Laporan & Presentasi

Semua berkas diawali dengan **Cover** (Identitas Mahasiswa & Judul Kasus).

Mahasiswa ke-1 (Data Engineer)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Preprocessing, Kesimpulan Sintesis).
- **Bab II: Metodologi Rekayasa Data** (Pipeline Pembersihan, Strategi Encoding, Logika Seleksi Fitur).
- **Bab III: Hasil & Pembahasan** (Analisis Statistik 79 Fitur, Visualisasi Korelasi, Efektivitas Pembersihan Missing Values).
- **Lampiran:** Script Program (Bagian Data Engineering).

Presentasi (P22):

- Slide 1: Identitas Mahasiswa & Judul Kasus.
- Slide 2: Ringkasan Literatur Rekayasa Data Properti.
- Slide 3: Alur Penanganan Fitur Berdimensi Tinggi.
- Slide 4: Hasil Seleksi Fitur dan Transformasi Data.

Mahasiswa ke-2 (Model Strategist)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Modeling/XAI, Kesimpulan Sintesis).
- **Bab II: Metodologi Pemodelan & Simulasi** (Pemilihan Algoritma Regresi, Strategi Regularisasi, Metode Evaluasi).
- **Bab III: Hasil & Pembahasan** (Analisis Skor R^2 & RMSE, Interpretasi SHAP, Simulasi Perubahan Aset dengan Data Sintetis).
- **Lampiran:** Script Program (Bagian Modeling & Simulation).

Presentasi (P22):

- Slide 1: Identitas Mahasiswa & Judul Kasus.
- Slide 2: Ringkasan Literatur Algoritma Regresi Properti.
- Slide 3: Arsitektur Model dan Parameter Optimasi.
- Slide 4: Penjelasan Logika Valuasi (SHAP).
- Slide 5: Simulasi Skenario Renovasi Properti (What-If).

9. Ketentuan Pengumpulan dan File

PERINGATAN: Algoritma antar kelompok **TIDAK BOLEH SAMA**. Segera klaim algoritma Anda melalui Google Form "**Klaim Metode Materi 2**".

- **Batas Waktu:** Cek file "Ringkasan Penugasan Pemodelan dan Simulasi 2026".
- **Link Pengumpulan:** Form "UNGGAH FILE JAWABAN" di deskripsi WAG.
- **Informasi Penting Pengumpulan:**
 - **Nama file bebas.**
 - **Format file harus sesuai** (PDF untuk dokumen/presentasi, MP4 untuk video).
 - **Kode soal harus sesuai** (P21 / P22 / R2).
 - **Jenis harus sesuai** (LAPORAN / PRESENTASI).
- **File yang dikumpulkan (Masing-masing Anggota):**
 - **PDF Laporan;** kode soal: **P21**; jenis: **LAPORAN**; format: **PDF**
 - **PDF Presentasi;** kode soal: **P22**; jenis: **LAPORAN**; format: **PDF**
 - **Video Presentasi;** kode soal: **R2**; jenis: **PRESENTASI**; format: **MP4** (720p, Wajib Video Overlay wajah presenter).

10. Penyesuaian untuk Kelompok Tunggal (1 Anggota)

Penyesuaian Beban Kerja

Mahasiswa mengerjakan seluruh alur (Data Engineer + Model Strategist) dengan kompensasi:

- Jumlah jurnal pada tabel sintesis minimal **3 jurnal**.
- Sampel uji simulator minimal **5 sampel**.

Sistematika Laporan (Kelompok Tunggal)

- **Bab I:** Pendahuluan & Sintesis Jurnal.
- **Bab II:** Metodologi (Data Engineering hingga Modeling).
- **Bab III:** Hasil & Pembahasan (Integrasi Performa & XAI).

Konten Presentasi (Kelompok Tunggal)

Mencakup ringkasan eksekutif dari pengolahan data hingga hasil simulasi kebijakan dalam satu file presentasi (P22) dan video (R2).

Soal Tugas Kelompok: Pemodelan dan Simulasi

Materi 2: Model Regresi Cross-Sectional

Kasus 4: Simulasi Estimasi Harga Berlian Berdasarkan Karakteristik Fisik (Diamond Pricing)

1. Latar Belakang dan Tujuan

Dalam pasar komoditas mewah, penentuan harga berlian sangat bergantung pada standar global yang dikenal dengan "4C" (*Carat, Cut, Color, Clarity*). Variasi kecil pada salah satu parameter ini dapat menyebabkan perbedaan harga hingga ribuan dollar. Bagi pedagang perhiasan dan pembeli, memiliki sistem simulasi yang mampu memberikan estimasi harga yang adil berdasarkan karakteristik fisik adalah alat bantu transaksi yang sangat berharga.

Masalah utama dalam pemodelan ini adalah adanya hubungan non-linear antara berat (karat) dengan harga, serta pengaruh subjektif dari kualitas potongan (*cut*) dan kejernihan (*clarity*) yang bersifat ordinal. Simulasi ini bertujuan untuk membangun model regresi yang mampu memprediksi "**price**" (harga dalam USD) secara akurat, sehingga dapat digunakan sebagai instrumen valuasi otomatis.

Tujuan Tugas:

- 1. Mahasiswa mampu mengolah data fisik perhiasan yang memiliki skala ordinal menjadi fitur numerik yang valid.
- 2. Mahasiswa mampu membangun model regresi untuk mengestimasi nilai kuantitas kontinu pada dataset ribuan baris.
- 3. Mahasiswa mampu membuktikan secara ilmiah variabel mana yang paling sensitif terhadap kenaikan harga melalui teknik XAI dan simulasi "What-If".

2. Karakteristik Dataset

Dataset ini berisi karakteristik fisik dan harga dari hampir 54.000 butir berlian.

- **Judul Dataset:** Diamonds Dataset.
- **Tautan Sumber:** [Kaggle - Diamonds Dataset](#).
- **Deskripsi:** Terdiri dari 53.940 baris data observasi dengan 10 atribut fitur.

Atribut Data:

Nama Atribut	Deskripsi	Tipe Data
carat	Berat berlian (0.2–5.01).	Float
cut	Kualitas potongan (Fair, Good, Very Good, Premium, Ideal).	Kategorikal (Ordinal)
color	Warna berlian, dari J (terburuk) ke D (terbaik).	Kategorikal (Ordinal)
clarity	Kejernihan (I1, SI2, SI1, VS2, VS1, VVS2, VVS1, IF).	Kategorikal (Ordinal)
x, y, z	Dimensi panjang, lebar, dan kedalaman dalam mm.	Float
depth	Persentase kedalaman total ($z/\text{mean}(x, y)$).	Float
table	Lebar bagian atas berlian relatif terhadap titik terlebar.	Float
price	Label Target: Harga dalam dollar AS (\$).	Integer

3. Pembagian Tugas dan Peran (Individual Job Desc)

Tugas dikerjakan oleh **2 mahasiswa per kelompok**. Laporan dan presentasi dilakukan secara mandiri oleh tiap anggota sesuai peran berikut:

Mahasiswa ke-1: Data Architect & Engineer

Fokus: Ordinal encoding, penanganan korelasi dimensi, dan standarisasi.

- 1. **Data Ingestion:** Akuisisi dataset dan pembersihan data dimensi yang bernilai nol (invalid).
- 2. **Ordinal Mapping:** Menerapkan teknik *Ordinal Encoding* pada fitur `cut`, `color`, dan `clarity` sesuai dengan tingkatan kualitas standarnya.
- 3. **Multicollinearity Audit:** Menganalisis korelasi antara `carat` dan dimensi `x`, `y`, `z` untuk menghindari redundansi fitur.
- 4. **Outlier Management:** Identifikasi dan penanganan nilai ekstrim pada fitur `price` yang dapat mendistorsi model.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

5. **Feature Scaling:** Melakukan standarisasi data agar perbedaan satuan (Karat vs mm) tidak mengganggu proses optimasi.

Mahasiswa ke-2: Model Analyst & Strategist

Fokus: Arsitektur regresi cerdas, evaluasi galat, dan simulasi pasar.

1. **Model Implementation:** Eksperimentasi algoritma regresi (Linear, Support Vector Regression, atau Ensemble) untuk mendapatkan tingkat presisi tertinggi.
2. **Model Assessment:** Evaluasi kualitas peramalan menggunakan metrik MAE, RMSE, dan R^2 .
3. **Explainable AI (XAI):** Menggunakan SHAP untuk membuktikan kontribusi tiap tingkat kualitas (misal: seberapa mahal kenaikan dari 'Good' ke 'Ideal?').
4. **Valuation Simulation:** Melakukan uji coba skenario "What-If" menggunakan **Data Sintetis**: "Jika berat berlian tetap namun tingkat kejernihan ditingkatkan dua level, berapa estimasi kenaikan harganya?"

4. Landasan Ilmiah (Tabel Sintesis Jurnal)

Mahasiswa wajib menyertakan tabel sintesis dari minimal **6 artikel jurnal ilmiah** (maksimal 5 tahun terakhir).

- **Jurnal Nasional:** Terakreditasi SINTA 1-4.
- **Jurnal Internasional:** Scopus, WoS, DOAJ, PubMed, atau IEEE Xplore.

Contoh Tabel Sintesis yang Baik:

No	Info Artikel (Penulis, Judul, Jurnal, Vol, No, Tahun, Tautan)	Metode	Temuan Utama	Relevansi
1	Utama, D., "Pemodelan Harga Barang Mewah," <i>Jurnal Komputer</i> , 12(1), 2023, [URL]	Gradient Boosting	Fitur karat memiliki pengaruh non-linear sebesar 70% terhadap harga.	Dasar penentuan algoritma regresi.
2	Miller, K., "Ordinal Data in ML," <i>Data Science Journal</i> , 8(2), 2024, [URL]	Ordinal Encoding	Pemetaan manual sesuai hirarki meningkatkan akurasi 15% dibanding OHE.	Rujukan teknik encoding ordinal.

Kesimpulan Sintesis: Mahasiswa wajib merangkum metode terbaik dalam menangani data perhiasan berdasarkan literatur tersebut.

5. Alur Kerja (ML Pipeline)

Penyelesaian harus selaras dengan buku **PEMODELAN DAN SIMULASI BERBASIS MACHINE LEARNING**:

1. **Data Acquisition:** Memuat dataset Diamonds dari Kaggle secara terprogram.
2. **EDA & Visualisasi:** Memahami hubungan antara Karat dan Harga (Scatter plot).
3. **Ordinal Encoding:** Transformasi fitur kualitas ke dalam skala numerik berjenjang.
4. **Preprocessing:** Pembersihan data dimensi (x, y, z) dan penskalaan.
5. **Modeling Phase:** Implementasi algoritma regresi pilihan kelompok.
6. **Model Assessment:** Evaluasi metrik R^2 , MAE, dan RMSE pada data uji.
7. **Explainability (XAI):** Analisis faktor pendorong nilai ekonomi menggunakan SHAP.
8. **Simulasi Intervensi:** Pengujian skenario "What-If" perubahan kualitas menggunakan data sintetis.

6. Deskripsi Program Aplikasi

Aplikasi harus memiliki modul simulator yang mampu menerima input spesifikasi fisik berlian (Karat, Cut, Color, Clarity) dan mengeluarkan output: **"ESTIMASI NILAI PASAR (USD)"**.

Cara Menguji Program:

Mahasiswa wajib menguji minimal **10 sampel data acak** dari dataset uji.

- **Hubungan dengan Model Assessment:** Hasil pengujian manual harus mencerminkan performa model. Jika MAE tinggi, maka prediksi manual pada 10 sampel ini akan memiliki selisih dollar yang cukup besar dengan harga pasar.

7. Hasil dan Pembahasan

Bagian ini wajib menyajikan:

- **Analisis Encoding:** Penjelasan mengenai urutan angka yang diberikan pada tiap kategori Cut/Color/Clarity.
- **Analisis Error:** Visualisasi grafik *Residual Plot* untuk melihat keandalan estimasi harga.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

- **Visualisasi SHAP:** Penjelasan fitur fisik mana yang paling krusial menentukan mahalnnya harga berlian.
- **Hasil What-If (Data Sintetis):** Tabel simulasi perubahan harga saat variabel Karat atau Kualitas potongan dimanipulasi secara virtual.

8. Sistematika Laporan & Presentasi

Semua berkas diawali dengan **Cover** (Identitas Mahasiswa & Judul Kasus).

Mahasiswa ke-1 (Data Engineer)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Preprocessing, Kesimpulan Sintesis).
- **Bab II: Metodologi Rekayasa Data** (Pipeline Preprocessing, Logika Ordinal Encoding, Strategi Penanganan Outlier).
- **Bab III: Hasil & Pembahasan** (Analisis Statistik Fitur, Visualisasi Korelasi, Efektivitas Transformasi Data).
- **Lampiran:** Script Program (Bagian Data Engineering).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Rekayasa Data Ordinal.
- 3: Alur Transformasi Fitur Kategorikal ke Numerik.
- 4: Analisis Sebaran Harga dan Dimensi Berlian.

Mahasiswa ke-2 (Model Strategist)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Regresi/XAI, Kesimpulan Sintesis).
- **Bab II: Metodologi Pemodelan & Simulasi** (Pemilihan Algoritma Regresi, Optimasi Parameter, Metode Evaluasi).
- **Bab III: Hasil & Pembahasan** (Analisis Skor R^2 & RMSE, Interpretasi SHAP, Simulasi Perubahan Kualitas dengan Data Sintetis).
- **Lampiran:** Script Program (Bagian Modeling & Simulation).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Algoritma Regresi.
- 3: Arsitektur Model dan Hasil Evaluasi Metrik.
- 4: Penjelasan Logika Harga (SHAP).
- 5: Simulasi Skenario Valuasi Berlian (What-If).

9. Ketentuan Pengumpulan dan File

PERINGATAN: Algoritma antar kelompok **TIDAK BOLEH SAMA**. Segera klaim algoritma Anda melalui Google Form "**Klaim Metode Materi 2**".

- **Batas Waktu:** Cek file "Ringkasan Penugasan Pemodelan dan Simulasi 2026".
- **Link Pengumpulan:** Form "UNGGAH FILE JAWABAN" di deskripsi WAG.
- **Informasi Penting Pengumpulan:**
 - **Nama file bebas.**
 - **Format file harus sesuai** (PDF untuk dokumen/presentasi, MP4 untuk video).
 - **Kode soal harus sesuai** (P21 / P22 / R2).
 - **Jenis harus sesuai** (LAPORAN / PRESENTASI).
- **File yang dikumpulkan (Masing-masing Anggota):**
 - **PDF Laporan;** kode soal: **P21**; jenis: **LAPORAN**; format: **PDF**
 - **PDF Presentasi;** kode soal: **P22**; jenis: **LAPORAN**; format: **PDF**
 - **Video Presentasi;** kode soal: **R2**; jenis: **PRESENTASI**; format: **MP4** (720p, Wajib Video Overlay wajah presenter).

10. Penyesuaian untuk Kelompok Tunggal (1 Anggota)

Penyesuaian Beban Kerja

Mahasiswa mengerjakan seluruh alur (Data Engineer + Model Strategist) dengan kompensasi:

- Jumlah jurnal pada tabel sintesis minimal **3 jurnal**.
- Sampel uji simulator minimal **5 sampel**.

Sistematika Laporan (Kelompok Tunggal)

- **Bab I:** Pendahuluan & Sintesis Jurnal.
- **Bab II:** Metodologi (Data Engineering hingga Modeling).
- **Bab III:** Hasil & Pembahasan (Integrasi Performa & XAI).

Konten Presentasi (Kelompok Tunggal)

Mencakup ringkasan eksekutif dari pengolahan data hingga hasil simulasi kebijakan dalam satu file presentasi (P22) dan video (R2).

Soal Tugas Kelompok: Pemodelan dan Simulasi

Materi 2: Model Regresi Cross-Sectional

Kasus 5: Simulasi Estimasi Harga Jual Mobil Bekas (Used Car Valuation)

1. Latar Belakang dan Tujuan

Pasar mobil bekas merupakan ekosistem ekonomi yang sangat dinamis. Bagi dealer maupun perorangan, menentukan harga jual yang kompetitif namun tetap menguntungkan adalah tantangan tersendiri. Harga sebuah kendaraan tidak hanya ditentukan oleh merek, tetapi sangat bergantung pada tingkat depresiasi yang dipengaruhi oleh usia kendaraan, jarak tempuh (kilometer), jenis bahan bakar, hingga riwayat kepemilikan. Masalah utama dalam pemodelan ini adalah sifat depresiasi harga yang sering kali tidak linear (harga turun drastis di tahun-tahun awal). Simulasi ini bertujuan untuk membangun model regresi yang mampu memprediksi "**Selling_Price**" (harga jual saat ini) secara akurat. Mahasiswa ditantang untuk mengubah fitur mentah menjadi fitur yang bermakna bagi mesin simulator, seperti menghitung usia kendaraan dari tahun produksi.

Tujuan Tugas:

- 1. Mahasiswa mampu melakukan rekayasa fitur (feature engineering) pada data aset yang memiliki variabel waktu dan penggunaan fisik.
- 2. Mahasiswa mampu membangun model regresi untuk mengestimasi nilai ekonomi barang modal secara presisi.
- 3. Mahasiswa mampu memberikan justifikasi ilmiah mengenai faktor depresiasi utama melalui teknik XAI dan simulasi "What-If".

2. Karakteristik Dataset

Dataset ini berisi data historis penjualan mobil bekas dari platform CarDekho.

- **Judul Dataset:** Vehicle Dataset from CarDekho.
- **Tautan Sumber:** [Kaggle - Car Data](#).
- **Deskripsi:** Terdiri dari data observasi kendaraan dengan fitur teknis dan riwayat pemakaian.

Atribut Data:

Nama Atribut	Deskripsi	Tipe Data
Year	Tahun pembuatan/pembelian mobil.	Integer
Selling_Price	Label Target: Harga saat mobil tersebut dijual (Lakhs).	Float
Present_Price	Harga baru mobil tersebut di showroom saat ini (Lakhs).	Float
Kms_Driven	Total jarak yang telah ditempuh kendaraan (km).	Integer
Fuel_Type	Jenis bahan bakar (Petrol, Diesel, CNG).	Kategorikal
Seller_Type	Tipe penjual (Dealer, Individual).	Kategorikal
Transmission	Jenis transmisi (Manual, Automatic).	Kategorikal
Owner	Jumlah pemilik sebelumnya (0, 1, 3).	Integer

3. Pembagian Tugas dan Peran (Individual Job Desc)

Tugas dikerjakan oleh **2 mahasiswa per kelompok**. Laporan dan presentasi dilakukan secara mandiri oleh tiap anggota sesuai peran berikut:

Mahasiswa ke-1: Data Architect & Engineer

Fokus: Rekayasa fitur usia, encoding teknis, dan pembersihan outlier.

- 1. **Data Ingestion:** Akuisisi dataset dan pengecekan tipe data mentah.
- 2. **Feature Engineering (Age):** Membuat fitur baru **Age** (Usia Mobil) dengan menghitung selisih tahun saat ini dengan kolom **Year**.
- 3. **Encoding Strategy:** Menerapkan *One-Hot Encoding* atau *Dummy Variables* pada fitur **Fuel_Type**, **Transmission**, dan **Seller_Type**.
- 4. **Outlier Management:** Identifikasi dan penanganan kendaraan dengan kilometer tempuh (**Kms_Driven**) yang sangat ekstrim.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

5. **Preprocessing Pipeline:** Melakukan standarisasi atau normalisasi fitur agar variabel dengan skala besar (Km) tidak mendominasi variabel skala kecil (Tahun).

Mahasiswa ke-2: Model Analyst & Strategist

Fokus: Arsitektur regresi depresiasi, audit galat, dan simulasi valuasi.

1. **Model Implementation:** Eksperimentasi algoritma regresi (Linear, SGD, atau algoritma non-linear lainnya) yang mampu menangani pola depresiasi harga.
2. **Model Assessment:** Evaluasi kualitas peramalan menggunakan metrik MAE, RMSE, dan R^2 .
3. **Explainable AI (XAI):** Menggunakan SHAP untuk membuktikan variabel mana yang paling menurunkan harga (misal: apakah usia lebih berpengaruh daripada kilometer?).
4. **Valuation Simulation:** Melakukan uji coba skenario "What-If" menggunakan **Data Sintetis**: "Jika sebuah mobil yang sama memiliki jarak tempuh 100.000 km lebih banyak, berapa perkiraan penurunan harganya menurut simulator?"

4. Landasan Ilmiah (Tabel Sintesis Jurnal)

Mahasiswa wajib menyertakan tabel sintesis dari minimal **6 artikel jurnal ilmiah** (maksimal 5 tahun terakhir).

- **Jurnal Nasional:** Terakreditasi SINTA 1-4.
- **Jurnal Internasional:** Scopus, WoS, DOAJ, PubMed, atau IEEE Xplore.

Contoh Tabel Sintesis yang Baik:

No	Info Artikel (Penulis, Judul, Jurnal, Vol, No, Tahun, Tautan)	Metode	Temuan Utama	Relevansi
1	Saputra, R., "Estimasi Depresiasi Kendaraan," <i>Jurnal Otomotif</i> , 12(2), 2023, [URL]	Regresi Linear	Usia kendaraan memiliki korelasi negatif -0.7 terhadap harga.	Dasar rekayasa fitur usia.
2	Chen, Y., "Machine Learning for Used Car Market," <i>Data Science Review</i> , 8(1), 2024, [URL]	Random Forest + SHAP	Jenis bahan bakar Diesel memiliki nilai jual kembali lebih tinggi 15%.	Rujukan analisis fitur kategorikal.

Kesimpulan Sintesis: Mahasiswa wajib merangkum tren metode dan variabel yang paling krusial dalam valuasi aset bergerak berdasarkan 6 literatur tersebut.

5. Alur Kerja (ML Pipeline)

Penyelesaian harus selaras dengan buku **PEMODELAN DAN SIMULASI BERBASIS MACHINE LEARNING**:

1. **Data Acquisition:** Memuat dataset Car Data dari Kaggle secara terprogram.
2. **EDA & Visualisasi:** Memahami distribusi harga jual dan pengaruh kilometer terhadap harga.
3. **Feature Engineering:** Transformasi tahun ke usia dan encoding kategorikal.
4. **Modeling Phase:** Implementasi algoritma regresi pilihan kelompok.
5. **Model Assessment:** Evaluasi performa pada data uji (Test Set).
6. **Explainability (XAI):** Analisis faktor pendorong nilai ekonomi menggunakan SHAP.
7. **Simulation & What-If:** Pengujian skenario depresiasi kendaraan menggunakan data input buatan (sintetis).

6. Deskripsi Program Aplikasi

Aplikasi harus memiliki modul simulator yang mampu menerima input: **Tahun, Harga Showroom, Kilometer, Bahan Bakar, dan Transmisi**. Output yang dihasilkan adalah: **"ESTIMASI HARGA JUAL LAYAK (LAKHS)"**.

Cara Menguji Program:

Mahasiswa wajib menguji minimal **10 sampel data acak** dari dataset uji.

- **Hubungan dengan Model Assessment:** Hasil pengujian manual harus mencerminkan nilai R^2 . Jika R^2 rendah, maka prediksi manual pada 10 sampel ini akan sering meleset jauh dari harga asli di pasar mobil bekas.

7. Hasil dan Pembahasan

Bagian ini wajib menyajikan:

- **Analisis Depresiasi:** Visualisasi hubungan antara Usia Mobil dengan Harga Jual (Scatter plot).
- **Analisis Error:** Visualisasi grafik *Actual vs Predicted* untuk melihat konsistensi model.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

- **Visualisasi SHAP:** Penjelasan fitur mana yang paling dominan mempertahankan harga (misal: apakah mobil Automatic lebih mahal?).
- **Hasil What-If (Data Sintetis):** Tabel simulasi perubahan harga saat variabel kilometer atau usia dimanipulasi secara virtual.

8. Sistematika Laporan & Presentasi

Semua berkas diawali dengan **Cover** (Identitas Mahasiswa & Judul Kasus).

Mahasiswa ke-1 (Data Engineer)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Preprocessing, Kesimpulan Sintesis).
- **Bab II: Metodologi Rekayasa Data** (Pipeline Preprocessing, Logika Hitung Usia, Strategi Encoding).
- **Bab III: Hasil & Pembahasan** (Analisis Statistik Fitur, Visualisasi Hubungan Usia-Harga, Efektivitas Scaling).
- **Lampiran:** Script Program (Bagian Data Engineering).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Rekayasa Data Aset.
- 3: Alur Transformasi Fitur (Tahun ke Usia).
- 4: Analisis Data Sebelum dan Sesudah Pembersihan.

Mahasiswa ke-2 (Model Strategist)

Laporan (P21):

- **Bab I: Pendahuluan** (Latar Belakang, Tujuan, Tabel Sintesis Jurnal khusus Regresi/XAI, Kesimpulan Sintesis).
- **Bab II: Metodologi Pemodelan & Simulasi** (Pemilihan Algoritma Regresi, Optimasi Parameter, Metode Evaluasi).
- **Bab III: Hasil & Pembahasan** (Analisis Presisi MAE/RMSE, Interpretasi SHAP, Simulasi Valuasi dengan Data Sintetis).
- **Lampiran:** Script Program (Bagian Modeling & Simulation).

Presentasi (P22):

- 1: Identitas Mahasiswa & Judul Kasus.
- 2: Ringkasan Literatur Algoritma Regresi Aset.
- 3: Arsitektur Model dan Hasil Evaluasi Metrik.
- 4: Penjelasan Logika Harga (SHAP).
- 5: Simulasi Skenario Depresiasi Harga (What-If Analysis).

9. Ketentuan Pengumpulan dan File

PERINGATAN: Algoritma antar kelompok **TIDAK BOLEH SAMA**. Segera klaim algoritma Anda melalui Google Form "**Klaim Metode Materi 2**".

- **Batas Waktu:** Cek file "Ringkasan Penugasan Pemodelan dan Simulasi 2026".
- **Link Pengumpulan:** Form "UNGGAH FILE JAWABAN" di deskripsi WAG.
- **Informasi Penting Pengumpulan:**
 - Nama file bebas.
 - Format file harus sesuai (PDF untuk dokumen/presentasi, MP4 untuk video).
 - Kode soal harus sesuai (P21 / P22 / R2).
 - Jenis harus sesuai (LAPORAN / PRESENTASI).
- **File yang dikumpulkan (Masing-masing Anggota):**
 - PDF Laporan; kode soal: **P21**; jenis: **LAPORAN**; format: **PDF**
 - PDF Presentasi; kode soal: **P22**; jenis: **LAPORAN**; format: **PDF**
 - Video Presentasi; kode soal: **R2**; jenis: **PRESENTASI**; format: **MP4** (720p, Wajib Video Overlay wajah presenter).

10. Penyesuaian untuk Kelompok Tunggal (1 Anggota)

Penyesuaian Beban Kerja

Mahasiswa mengerjakan seluruh alur (Data Engineer + Model Strategist) dengan kompensasi:

- Jumlah jurnal pada tabel sintesis minimal **3 jurnal**.
- Sampel uji simulator minimal **5 sampel**.

Sistematika Laporan (Kelompok Tunggal)

- **Bab I:** Pendahuluan & Sintesis Jurnal.
- **Bab II:** Metodologi (Data Engineering hingga Modeling).
- **Bab III:** Hasil & Pembahasan (Integrasi Performa & XAI).

Konten Presentasi (Kelompok Tunggal)

Mencakup ringkasan eksekutif dari pengolahan data hingga hasil simulasi kebijakan dalam satu file presentasi (P22) dan video (R2).

Panduan Penggunaan Data Sintetis dalam Tugas Kelompok

Materi 2: Model Regresi Cross-Sectional

1. Pengantar Data Sintetis untuk Regresi

Dalam pemodelan regresi, data sintetis berperan sebagai instrumen untuk menguji fungsi pemetaan target kontinu $y = f(X)$. Berbeda dengan klasifikasi yang berfokus pada batas kelompok, pada regresi kita menggunakan data sintetis untuk melihat sejauh mana "garis prediksi" model mampu menangani perubahan nilai fitur secara halus (*granularity*) maupun ekstrem.

Mahasiswa akan menggunakan Python untuk membangkitkan baris data baru yang mewakili skenario hipotetis. Hal ini memungkinkan mahasiswa untuk melihat elastisitas variabel (misal: "Berapa kenaikan harga rumah jika luasnya ditambah 10 meter?") tanpa perlu mencari data rumah nyata yang persis seperti itu.

2. Tujuan dan Manfaat Data Sintetis

- **Analisis Sensitivitas (Sensitivity Analysis):** Mengetahui variabel mana yang paling cepat mengubah nilai output ketika nilainya digeser sedikit demi sedikit.
- **Uji Ekstrapolasi:** Menguji perilaku model saat menghadapi input di batas maksimal atau minimal data asli untuk melihat apakah model tetap memberikan angka yang logis.
- **Simulasi Kebijakan (What-If):** Memberikan dasar kuantitatif bagi rekomendasi tindakan, seperti simulasi penghematan biaya atau peningkatan valuasi aset.
- **Pembersihan Outlier:** Membuat data sintetis yang bersih sebagai pembanding untuk mendeteksi apakah data asli yang ekstrem merusak garis tren regresi.

3. Petunjuk Penggunaan pada Tiap Kasus Materi 2

Mahasiswa wajib menyertakan minimal 5-10 baris data sintetis untuk analisis "What-If" pada kasus yang didapat dengan ketentuan sebagai berikut:

Kasus 1: Estimasi Biaya Taksi NYC

- **Tugas:** Simulasi dampak kemacetan dan waktu tempuh.
- **Petunjuk:** Bangkitkan data sintetis dengan koordinat jemput-tujuan yang sama, namun ubah fitur jam penjemputan (`pickup_hour`) dari jam lancar (03:00) ke jam sibuk (17:00).
- **Risiko:** Menciptakan koordinat GPS yang berada di luar batas wilayah New York (misal: di tengah laut).
- **Dampak:** Model akan memberikan estimasi tarif yang tidak masuk akal (terlalu murah atau terlalu mahal) karena berada di luar domain pengetahuan geografisnya.

Kasus 2: Healthcare Cost Estimation

- **Tugas:** Simulasi perubahan gaya hidup terhadap premi.
- **Petunjuk:** Ambil profil seorang nasabah perokok, lalu buat data sintetis di mana variabel `smoker` diubah menjadi `no` dan `bmi` diturunkan secara bertahap.
- **Risiko:** Menciptakan kombinasi fitur yang tidak mungkin secara biologis (misal: BMI sangat rendah dengan usia sangat tua).
- **Dampak:** Prediksi penurunan biaya medis mungkin terlihat linear, padahal secara medis risiko penyakit biasanya turun secara eksponensial.

Kasus 3: Property Valuation (Ames Housing)

- **Tugas:** Simulasi renovasi dan peningkatan kualitas.
- **Petunjuk:** Bangkitkan data sintetis di mana fitur `OverallQual` (Kualitas Keseluruhan) dinaikkan dari skor 5 ke 9 pada rumah yang sama.
- **Risiko:** Mengabaikan hukum penyusutan aset (depresiasi) pada rumah lama yang direnovasi secara mewah.
- **Dampak:** Model mungkin memprediksi harga yang terlalu optimis, melebihi harga pasar rumah baru di lingkungan yang sama.

Kasus 4: Diamond Pricing

- **Tugas:** Simulasi nilai kelangkaan.
- **Petunjuk:** Buat data sintetis dengan menaikkan variabel `carat` melewati batas maksimal data asli (misal: 10 karat) untuk melihat apakah model regresi masih mampu memprediksi harga secara stabil.

Tugas Kelompok Materi ke-2 (Model Regresi Cross-Sectional)

- **Risiko:** Terjadi *Exploding Prediction* pada model non-linear atau JST.
- **Dampak:** Harga yang diprediksi bisa menjadi negatif atau sangat besar (tak terhingga) jika model gagal menangani ekstrapolasi data mewah.

Kasus 5: Used Car Pricing

- **Tugas:** Simulasi depresiasi nilai aset.
- **Petunjuk:** Gunakan `np.linspace()` untuk membangkitkan data sintetis variabel `Kms_Driven` dari 10.000 km hingga 500.000 km pada mobil yang tahunnya sama.
- **Risiko:** Hubungan antara jarak tempuh dan harga mungkin tidak lagi linear setelah titik tertentu.
- **Dampak:** Model mungkin memprediksi harga mobil menjadi Rp 0 atau minus pada kilometer yang sangat tinggi, yang secara ekonomi tidak valid karena mobil masih memiliki nilai besi tua.

4. Etika Penggunaan Data Sintetis

1. **Transparansi Pelaporan:** Mahasiswa dilarang mencampur data sintetis ke dalam *Test Set* asli untuk meningkatkan skor R^2 . Data sintetis hanya digunakan untuk tahap **Analisis Hasil**.
2. **Logika Domain:** Nilai sintetis yang dibuat harus tetap berada dalam batas hukum fisika atau logika bisnis yang berlaku pada kasus tersebut.
3. **No Manipulation:** Dilarang menggunakan data sintetis untuk menutupi kelemahan model (misal: membuat data sintetis agar garis regresi terlihat lebih rapi daripada kenyataannya).
4. **Integritas Akademik:** Penggunaan data sintetis harus disertai dengan penjelasan algoritma pembuatannya (misal: menggunakan fungsi `random.uniform` atau `np.linspace`).

5. Ketentuan dalam Laporan

Pada Bab III (Hasil dan Pembahasan), mahasiswa wajib menyediakan sub-bab "**Simulasi Intervensi Skenario**" yang berisi:

- Tabel perbandingan input (Asli vs Sintetis).
- Analisis perubahan output (Delta Δy).
- Kesimpulan apakah model regresi tersebut cukup sensitif dan logis dalam menanggapi skenario buatan tersebut.